

Programación y Administración de Sistemas

Práctica 2. Expresiones regulares para programación de la *Shell*

M^a Isabel Jiménez Velasco

Asignatura “Programación y Administración de Sistemas”
2º Curso Grado en Ingeniería Informática
Escuela Politécnica Superior
(Universidad de Córdoba)
i72jivem@uco.es

7 de marzo de 2023



Objetivos del aprendizaje I

- Definir qué es una expresión regular.
- Justificar la necesidad de las expresiones regulares y su importancia en la programación de *scripts* para administración de sistemas.
- Distinguir entre expresiones regulares básicas y expresiones regulares extendidas.
- Entender el significado de los distintos caracteres especiales que se pueden utilizar para expresiones regulares.
- Ser capaz de interpretar una expresión regular.
- Ser capaz de escribir expresiones regulares dada una especificación.
- Utilizar correctamente expresiones regulares para el comando **grep**.
- Utilizar correctamente expresiones regulares para el comando **sed**.

- ❶ Expresiones regulares.
 - ❶.1 Concepto.
 - ❶.2 Justificación.
 - ❶.3 Caracteres especiales.
- ❷ Comandos.
 - ❷.1 `grep` y `egrep`.
 - ❷.2 `sed`.

- Pruebas de validación de prácticas.

¿Qué son las expresiones regulares?

- Una expresión regular (*regex*) describe un conjunto de cadenas de texto.
- Se utilizan:
 - En entornos UNIX, con comandos como `grep`, `sed`, `awk`...
 - De manera intensiva, en lenguajes de programación como `perl`, `python`, `ruby`...
 - En bases de datos.
- Ahorran **mucho tiempo** y hacen el código más **robusto**.



¿Qué son las expresiones regulares?

- La expresión regular más simple sería la que busca una secuencia fija de caracteres **literales**.
- La cadena cumple la expresión regular si contiene esa secuencia.

ola

Ella me dijo hola. ⇒ **Empareja**.

Ella me dijo mola. ⇒ **Empareja**.

Ella me dijo adiós. ⇒ **No empareja**.



¿Qué son las expresiones regulares?

- Puede que la expresión regular empareje a la cadena en más de un punto:

ola me dijo ola. \Rightarrow Empareja 2 veces.

- El carácter “.” empareja cualquier cosa:

ola. me dijo ola. \Rightarrow Empareja 2 veces.



¿Por qué las necesito?

- ¿Para qué necesito aprender a utilizar las *regex*?
- Historia real¹:
 - Direcciones de calles.
 - Quiero actualizar su formato, de “100 NORTH MAIN ROAD” a “100 NORTH MAIN RD.”, sobre un conjunto de muchas carreteras.

```
1 i72jivem@VTS3:~/PAS/p2$ echo "100 NORTH MAIN ROAD" | sed -e 's/ROAD/RD\./'
2 100 NORTH MAIN RD.
3 i72jivem@VTS3:~/PAS/p2$ cat carreteras.txt
4 100 NORTH MAIN ROAD
5 45 ST JAMES ROAD
6 100 NORTH BROAD ROAD
7 i72jivem@VTS3:~/PAS/p2$ cat carreteras.txt | sed -e 's/ROAD/RD\./'
8 100 NORTH MAIN RD.
9 45 ST JAMES RD.
10 100 NORTH BRD. ROAD
```

¹https://linux.die.net/diveintopython/html/regular_expressions/street_addresses.html



¿Por qué las necesito?

- ¿Para qué necesito aprender a utilizar las *regex*?
 - A veces necesito hacer operaciones con cadenas con expresiones relativamente complejas.
 - P.Ej.: reemplazar “ROAD” por “RD.” siempre que esté al final de la línea (carácter especial \$).

```
1 i72jivem@VTS3:~/PAS/p2$ cat carreteras.txt | sed -e 's/ROAD$/RD\./'  
2 100 NORTH MAIN RD.  
3 45 ST JAMES RD.  
4 100 NORTH BROAD RD.
```



Caracteres especiales

- Las expresiones regulares se componen de caracteres normales (literales) y de caracteres especiales (o metacaracteres).
- “[...]”: sirve para indicar una lista caracteres posibles:

b[iur]e
Octubre me dijo bueno bien. ⇒ Empareja 3 veces.
- “[^...]”: sirve para *negar* la ocurrencia de uno o más caracteres:

b[^ur]e
Octubre me dijo bueno bien. ⇒ Empareja 1 vez.



Caracteres especiales

- “^”: empareja con el principio de una línea:

[^]O

Octubre me dijo bueno \Rightarrow Empareja 1 vez.

- “\$”: empareja con el final de una línea:

e^{\$}

Bueno, me dijo octubree \Rightarrow Empareja 1 vez.



Caracteres especiales

- “*”: empareja con cero, una o más ocurrencias del carácter anterior:

ola*s

Holaaaaaaas \Rightarrow Empareja 1 vez.

Hols \Rightarrow Empareja 1 vez.

- En caso de duda, el emparejamiento siempre es el de mayor longitud:

a.*e

Olas emocionantes.



Caracteres especiales

- Los paréntesis `()` (o `\(\|)`) permiten agrupar caracteres a la hora de aplicar los metacaracteres:
 - `a*` empareja `a`, `aa`, `aaa...`
 - `abc*` empareja `ab`, `abc`, `abcc`, `abccc...`
 - `(abc)*` empareja `abc`, `abcabc`, `abcabcabc...`
- Dos tipos de expresiones regulares:
 - *Basic Regular Expressions* (BRE): propuesta inicial en el estándar POSIX.
 - *Extended Regular Expressions* (ERE): ampliación con nuevos metacaracteres.
- Cada aplicación utiliza una u otra.



Caracteres especiales

| Carácter | BRE | ERE | Significado |
|----------|-----|-----|---|
| \ | ✓ | ✓ | Interpreta de forma literal el siguiente carácter |
| . | ✓ | ✓ | Selecciona un carácter cualquiera |
| * | ✓ | ✓ | Selecciona ninguna, una o varias veces lo anterior |
| ^ | ✓ | ✓ | Principio de línea |
| \$ | ✓ | ✓ | Final de línea |
| [...] | ✓ | ✓ | Cualquiera de los caracteres que hay entre corchetes |
| \n | ✓ | ✓ | Utilizar la <i>n</i> -ésima selección almacenada |
| {n,m} | X | ✓ | Selecciona lo anterior entre <i>n</i> y <i>m</i> veces |
| + | X | ✓ | Selecciona una o varias veces lo anterior |
| ? | X | ✓ | Selecciona una o ninguna vez lo anterior |
| | X | ✓ | Selecciona lo anterior o lo posterior |
| (...) | X | ✓ | Selecciona la secuencia que hay entre paréntesis ² |
| \{n,m\} | ✓ | X | Selecciona lo anterior entre <i>n</i> y <i>m</i> veces |
| \(...\) | ✓ | X | Selecciona la secuencia que hay entre paréntesis ² |
| \\ | ✓ | X | Selecciona lo anterior o lo posterior |

²Se almacena la selección



Rangos de caracteres

- `[aeiou]`: empareja con las letras `a`, `e`, `i`, `o` y `u`.
- `[1-9]` es equivalente a `[123456789]`.
- `[a-e]` es equivalente a `[abcde]`.
- `[1-9a-e]` es equivalente a `[123456789abcde]`.
- Los rangos típicos se pueden especificar de la siguiente forma:
 - `[[:alpha:]]` → `[a-zA-Z]`.
 - `[[:alnum:]]` → `[a-zA-Z0-9]`.
 - `[[:lower:]]` → `[a-z]`.
 - `[[:upper:]]` → `[A-Z]`.
 - `[R[:lower:]]` → `[Ra-z]`.
 - Otros³: *digit*, *punct*, *cntrl*, *blank*...

³`man wctype`



Otros ejemplos

| Expresión Regular | Equivalencia |
|------------------------|--|
| a.b | a x b a a b a b b a S b a # b ... |
| a..b | a x x b a a a b a b b b a 4 \$ b ... |
| [abc] | a b c (cadenas de un caracter) |
| [aA] | a A (cadenas de un caracter) |
| [aA][bB] | a A b A a B AB (cadenas de dos caracteres) |
| [0123456789] | 0 1 2 3 4 5 6 7 8 9 |
| [0-9] | 0 1 2 3 4 5 6 7 8 9 |
| [A-Za-z] | A B C ... Z a b c ... z |
| [0-9][0-9][0-9] | 000 001 .. 009 010 .. 019 100 .. 999 |
| [0-9]* | cadena_vacía 0 1 9 00 99 123 456 999 9999 ... |
| [0-9][0-9]* | 0 1 9 00 99 123 456 999 9999 99999 99999999 ... |
| ^.*\$ | cualquier línea completa |



Otros ejemplos

| Expresion regular | Se unifica con... |
|----------------------------|---|
| <code>[0-9]+</code> | 0 1 9 00 99 123 456 999 9999 99999 999999999 .. |
| <code>[0-9]?</code> | cadena_vacia 0 1 2 .. 9 |
| <code>^a b</code> | a b |
| <code>(ab)*</code> | cadena_vacia ab abab ababab ... |
| <code>^[0-9]?b</code> | b 0b 1b 2b .. 9b |
| <code>(([0-9]+ab)*)</code> | cadena_vacia 1234ab 9ab9ab9ab 9876543210ab 99ab99ab ... |



Comando grep

- **grep** proviene del editor **ed** (editor de texto Unix), y en concreto, de su comando de búsqueda de expresiones regulares “**g**lobal **r**egular **e**xpression **p**rint”.
- Se utiliza cuando sabes que un fichero contiene una determinada expresión y quieres saber qué fichero es.
- **grep** utiliza las BRE, **egrep** utiliza las ERE (no obstante, podemos usar **grep -E** para que considere ERE).
- **Consejo:** antes de incluirlas en el *script*, probar las expresiones regulares en la consola con **grep**.
- Si usamos **grep --color** se resaltan en rojo los emparejamientos:
 - Si no lo tenéis activo, es buena idea incluir un alias en `.bashrc: alias grep='grep --color'`.



Comando grep

- Como muchos de los caracteres especiales de las *regex* son también especiales en **bash**, es una buena costumbre rodear la *regex* con comillas simples ('*expr*') cuando estemos escribiendo un *script* → Siempre que la *regex* no contenga variables de **bash**.
- **-i**: hace que considere igual mayúsculas y minúsculas.
- **-o**: en lugar de imprimir las líneas completas que cumplen el patrón, solo muestra el emparejamiento del patrón.
- **-v**: mostrar las líneas que **no** cumplen el patrón.
- **-e**: Nos permite especificar varios patrones de búsqueda.
(grep -e 'perro' -e 'gato' fichero.txt)



Comando grep

```
1 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt
2 Este es otro ejemplo de expresiones regulares
3 La segunda parte ya la veremos
4 ,,,adios,hola
5 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | grep '^E'
6 Este es otro ejemplo de expresiones regulares
7 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | grep -E '^(E|L)'
8 Este es otro ejemplo de expresiones regulares
9 La segunda parte ya la veremos
10 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | grep -E ',*'
11 Este es otro ejemplo de expresiones regulares
12 La segunda parte ya la veremos
13 ,,,adios,hola
14 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | grep -E ',+'
15 ,,,adios,hola
16 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | grep -E ',+' -o
17 ,,,
18 ,
19 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | grep -E 'L(..)*\1'
20 La segunda parte ya la veremos
```



Comando grep

- Encontrar todos los números con signo (con posibilidad o no de decimales):

`[-+] [0-9] + (\ . [0-9] +) ?`

```
1 i72jivem@VTS3:~/PAS/p2$ grep -E '[ -+ ] [ 0-9 ] + ( \ . [ 0-9 ] + ) ?' $(find -name "*.c")
2 ./svorex/loadfile.c:
3 ./gpor/lgam1.c:          strcat (buf, pstr+4) ;
                           -0.0002109075,0.0742379071,0.0815782188,
```

- 5 cifras decimales o más (sin signo):

`[0-9] + \ . [0-9] { 5 , }`

```
1 i72jivem@VTS3:~/PAS/p2$ grep -E '[ 0-9 ] + \ . [ 0-9 ] { 5 , }' $(find -name "*.c")
2 ./gpor/lgam1.c:          -0.0002109075,0.0742379071,0.0815782188,
```



Comando sed

- Es parecido a **grep** pero permite **cambiar** las líneas que encuentra (en lugar de solo mostrarlas).
- En realidad, es un editor de textos no interactivo, que recibe sus comandos como si fuesen un *script*.
- Los comandos que utiliza son los mismos que los de **ed**.
- Solo vamos a estudiar algunos de los comandos posibles.
- Por defecto, todas las líneas se imprimen tras aplicar el comando.



Comando sed

- `sed [-r] [-n] -e 'comando' [archivo]:`
 - `-r`: uso de EREs en lugar de BREs.
 - `-n`: modo silencioso → para imprimir una línea tienes que indicarlo explícitamente mediante el comando `p` (*print*).
 - `-e 'comando'`: ejecutar el comando o comandos especificados.
 - Sintaxis de comandos:
`[direccionInicio[, direccionFin]] [!] comando`
`[argumentos]:`
 - Si la dirección es adecuada, entonces se ejecutan los comandos (con sus argumentos).
 - Las direcciones pueden ser expresiones regulares (`/regex/`) o números de línea (`1`).
 - Si no hay `direccionFin` solo se aplica sobre `direccionInicio`.
 - `!` emparejaría todas las direcciones distintas que la indicada.



Comando sed

- **d**: borrar líneas direccionadas.
- **p**: imprimir líneas direccionadas.
- **s**: sustituir una expresión por otra sobre las líneas seleccionadas. Sintaxis:

s/patron/reemplazo/[banderas]

- **patron**: expresión regular BRE.
- **reemplazo**: cadena con qué reemplazarla.
- Bandera **n**, siendo *n* un número entero: reemplazar sólo la ocurrencia *n*-ésima.
- Bandera **g**: reemplazar todas las ocurrencias.
- Bandera **p**: forzar a imprimir la línea (solo tiene sentido si hemos utilizado **-n**).



Comando sed

```
1 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt
2 Este es otro ejemplo de expresiones regulares
3 La segunda parte ya la veremos
4 ,,,adios,hola
5 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -e '3p'
6 Este es otro ejemplo de expresiones regulares
7 La segunda parte ya la veremos
8 ,,,adios,hola
9 ,,,adios,hola
10 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -n -e '3p'
11 ,,,adios,hola
12 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -n -e '1,2p'
13 Este es otro ejemplo de expresiones regulares
14 La segunda parte ya la veremos
15 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -n -e '1,2!p'
16 ,,,adios,hola
17 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -e '/~L/d'
18 Este es otro ejemplo de expresiones regulares
19 ,,,adios,hola
20 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -e '2,$d'
21 Este es otro ejemplo de expresiones regulares
22 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -e '1,/s$/d'
23 ,,,adios,hola
```



Comando sed

```
1 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt
2 Este es otro ejemplo de expresiones regulares
3 La segunda parte ya la veremos
4 ,,,adidos,hola
5 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -r -e 's/La/El/'
6 Este es otro ejemplo de expresiones regulares
7 El segunda parte ya la veremos
8 ,,,adidos,hola
9 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -r -e 's/[Ll]a/El/'
10 Este es otro ejemplo de expresiones reguElres
11 El segunda parte ya la veremos
12 ,,,adidos,hoEl
13 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -r -e 's/([Ll])a/era\1/'
14 Este es otro ejemplo de expresiones regueralres
15 eraL segunda parte ya la veremos
16 ,,,adidos,hoeral
17 i72jivem@VTS3:~/PAS/p2$ cat ejemplo.txt | sed -r -n -e 's/(d[ea])/"\1"/p'
18 Este es otro ejemplo "de" expresiones regulares
19 La segun"da" parte ya la veremos
20 i72jivem@VTS3:~/PAS/p2$ cat ejemplo2.txt
21 Grado:Informatica
22 Informatica2:Grado2
23 i72jivem@VTS3:~/PAS/p2$ cat ejemplo2.txt | sed -r -n -e 's/(.*):(.*)/2:\1/p'
24 Informatica:Grado
25 Grado2:Informatica2
```



Comando sed

- Ejercicio: Utilizar expresiones regulares con sed, para transformar la salida del comando df al formato indicado abajo.

```
1 i72jivem@VTS3:~/PAS/p2$ ./espacioLibre.sh
2 El fichero de bloques udev, montado en /dev, tiene usados 0 bloques de un total
  de 8072372 (porcentaje de 0%).
3 El fichero de bloques tmpfs, montado en /run, tiene usados 1684 bloques de un
  total de 1627732 (porcentaje de 1%).
4 El fichero de bloques /dev/nvme0n1p6, montado en /, tiene usados 26204344
  bloques de un total de 60213124 (porcentaje de 46%).
5 El fichero de bloques tmpfs, montado en /dev/shm, tiene usados 200400 bloques de
  un total de 8138640 (porcentaje de 3%).
6 El fichero de bloques tmpfs, montado en /run/lock, tiene usados 4 bloques de un
  total de 5120 (porcentaje de 1%).
7 El fichero de bloques tmpfs, montado en /sys/fs/cgroup, tiene usados 0 bloques
  de un total de 8138640 (porcentaje de 0%).
8 El fichero de bloques /dev/nvme0n1p5, montado en /home, tiene usados 110324328
  bloques de un total de 328804660 (porcentaje de 36%).
9 El fichero de bloques /dev/nvme0n1p1, montado en /boot/efi, tiene usados 32952
  bloques de un total de 262144 (porcentaje de 13%).
10 El fichero de bloques tmpfs, montado en /run/user/1000, tiene usados 92 bloques
    de un total de 1627728 (porcentaje de 1%).
```



Referencias

- [1] Stephen G. Kochan y Patrick Wood Unix shell programming. Sams Publishing. Tercera Edición. 2003.
- [2] Evi Nemeth, Garth Snyder, Trent R. Hein y Ben Whaley Unix and Linux system administration handbook. Capítulo 2. *Scripting and the shell*. Prentice Hall. Cuarta edición. 2010.
- [3] Aeleen Frisch. Essential system administration. Apéndice. *Administrative Shell Programming*. O'Reilly and Associates. Tercera edición. 2002.



Programación y Administración de Sistemas

Práctica 2. Expresiones regulares para programación de la *Shell*

M^a Isabel Jiménez Velasco

Asignatura “Programación y Administración de Sistemas”
2º Curso Grado en Ingeniería Informática
Escuela Politécnica Superior
(Universidad de Córdoba)
i72jivem@uco.es

7 de marzo de 2023

